

# Implementierung des Sobelfilters in C und Assembler

Manuel Schnaus, Leonhard Chen und Stefan Gruber

Technische Universität München

Fakultät für Informatik

Lehrstuhl für Rechnerarchitektur und Parallele Systeme

München, der 03. März 2020





# Einleitung

- Sobel-Filter hebt Umrisse im Bild hervor
- Filtert horizontal und vertikal und fügt Ausgabe-Bilder zusammen
- Definition des Sobel-Filters:

1. 
$$A^{v} = M^{v} * E$$

2. 
$$A_{(x,y)}^{v,F} = \sum_{i=-k}^{k} \sum_{j=-k}^{k} M_{(k+i,k+j)}^{v} \cdot E_{(x+i,y+j)}^{F}$$

3. 
$$p_{(x,y)} = (R_{(x,y)}, G_{(x,y)}, B_{(x,y)})$$

4. 
$$G_{(x,y)}^F = \sqrt{(A_{(x,y)}^{v,F})^2 + (A_{(x,y)}^{h,F})^2}$$



#### **Algorithm 1:** Mathematischer Filter-Algorithmus

**Data:** Eingabebild  $E \in \mathbb{R}^{b \times h \times 3}$ , Ausgabebild  $G \in \mathbb{R}^{b \times h \times 3}$ , Breite des Bildes  $b \in \mathbb{N}$ , Höhe des Bildes  $h \in \mathbb{N}$  $M^{h} = \begin{pmatrix} 1 & 0 & -1 \\ 2 & 0 & -2 \\ 1 & 0 & -1 \end{pmatrix}, M^{v} = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 0 & 0 \\ -1 & -2 & -1 \end{pmatrix}$ y=1while y < h - 1 do x = 1while x < b - 1 do  $A_{(x,y)}^{v} = \sum_{i=-1}^{1} \sum_{j=-1}^{1} M_{(1+i,1+j)}^{v} \cdot E_{(x+i,y+j)}$   $A_{(x,y)}^{h} = \sum_{i=-1}^{1} \sum_{j=-1}^{1} M_{(1+i,1+j)}^{h} \cdot E_{(x+i,y+j)}$   $G_{(x,y)} = \sqrt{(A_{(x,y)}^{v})^{2} + (A_{(x,y)}^{h})^{2}}$  x = x + 1



$$A_{(x,y)}^v = E_{(x-1,y-1)}$$



$$E_{(x-1,y-1)}$$
  $E_{(x,y-1)}$   $E_{(x+1,y-1)}$   $E_{(x+1,y-1)}$   $E_{(x-1,y)}$   $E_{(x,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y+1)}$ 

$$A_{(x,y)}^{v} = E_{(x-1,y-1)} + 2 E_{(x,y-1)}$$



$$E_{(x-1,y-1)}$$
  $E_{(x,y-1)}$   $E_{(x+1,y-1)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y+1)}$   $E_{(x+1,y+1)}$ 

$$A_{(x,y)}^{v} = E_{(x-1,y-1)} + 2 E_{(x,y-1)} + E_{(x+1,y-1)}$$



$$E_{(x-1,y-1)}$$
  $E_{(x,y-1)}$   $E_{(x+1,y-1)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y+1)}$   $E_{(x,y+1)}$   $E_{(x+1,y+1)}$ 

$$A_{(x,y)}^{v} = E_{(x-1,y-1)} + 2E_{(x,y-1)} + E_{(x,+1,y-1)} - E_{(x-1,y+1)}$$



$$E_{(x-1,y-1)}$$
  $E_{(x,y-1)}$   $E_{(x+1,y-1)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y+1)}$   $E_{(x+1,y+1)}$ 

$$A_{(x,y)}^{v} = E_{(x-1,y-1)} + 2E_{(x,y-1)} + E_{(x,+1,y-1)} - E_{(x-1,y+1)} - 2E_{(x,y+1)}$$



$$E_{(x-1,y-1)}$$
  $E_{(x,y-1)}$   $E_{(x+1,y-1)}$   $E_{(x+1,y)}$   $E_{(x-1,y)}$   $E_{(x-1,y)}$   $E_{(x,y)}$   $E_{(x+1,y)}$   $E_{(x+1,y+1)}$ 

$$A_{(x,y)}^{v} = E_{(x-1,y-1)} + 2 E_{(x,y-1)} + E_{(x,+1,y-1)} - E_{(x-1,y+1)} - 2E_{(x,y+1)} - E_{(x+1,y+1)}$$



Ersetzen der Matrix-Zugriffe durch eine einheitliche Summe

$$A_{(x,y)}^{v} = E_{(x-1,y-1)} + 2 E_{(x,y-1)} + E_{(x,+1,y-1)} - E_{(x-1,y+1)} - 2E_{(x,y+1)} - E_{(x+1,y+1)}$$
 und

$$A_{(x,y)}^{h} = E_{(x-1,y-1)} - E_{(x,+1,y-1)} + 2E_{(x-1,y)} - 2E_{(x+1,y)} + E_{(x-1,y)} - E_{(x+1,y+1)}$$

- Vorteile: Keine Speicherzugriffe auf die Falungsmatrizen, keine mit 0 multiplizierte Elemente berücksichtigt
- Vier der sechs Elemente werden sowohl für die Berechnung von  $A^{\nu}_{(x,y)}$  als auch  $A^{h}_{(x,y)}$  benötigt
- → Gleichzeitige Berechnung beider Werte zur Einsparung von Load-Operationen



- Verarbeitung von Bildern der Farbtiefe 24bpp → 8 Bit pro Farbkanal eines Pixels
- Die einzelnen Farbkanäle eines Pixels im Ausgabe-Bild sind nicht voneinander abhängig
- Schleife über die Farbkanäle des Bildes statt über die Pixel → auf jedes Byte des Eingabe-Arrays wird separat die Formel angewandt
- Umsetzung in einer einfachen Schleife über die Speicheradresse des Input-Arrays mit einem Counter über der Breite



#### Algorithm 2: Optimierter Filter-Algorithmus

```
Data: Eingabebild E[], Ausgabebild G[], Breite des Bildes b, Höhe des Bildes h
E_{max} = b \cdot h \cdot 3 - b \cdot 6 - 6 + E
w = 0
while E < E_{max} do
    if w = 3 \cdot (b-2) then
        w = 0
     continue
    A^{v,F} = E[0] + 2 \cdot E[3] + E[6] - E[6 \cdot b] - 2 \cdot E[6 \cdot b + 3] - E[6 \cdot b + 6]
    A^{h,F} = E[0] - E[6] + 2 \cdot E[3 \cdot b] - 2 \cdot E[3 \cdot b + 6] + E[6 \cdot b] - E[6 \cdot b + 6]
    G^F = \sqrt{(A^{v,F})^2 + (A^{h,F})^2}
    w = w + 1
```



- Ausführung der Rechnung erfolgt mit einem Offset von einem Byte in jedem Schleifendurchlauf gleich und unabhängig voneinander
- → SIMD Optimierung bietet sich an
  - 16 Farbkanäle können in ein SIMD-Register geladen werden
  - Schwierigkeit: Aufgrund der Additionen und Multiplikationen reichen 8-Bit Werte nicht
- Lösung: Erweiterung der 8-Bit Lanes auf 16-Bit Lanes mit dem Befehl uxt1/uxt12
- Verrechnung der mit Zwei multiplizierten Werte nach der Erweiterung mit ushll
- Nur noch 8 Farbkanäle werden gleichzeitig berechnet



$$G_{(x,y)}^F = \sqrt{(A_{(x,y)}^v)^2 + (A_{(x,y)}^h)^2}$$

- Vor der Quadrierung der Werte  $A^{v}_{(x,y)}$  und  $A^{h}_{(x,y)}$  Aufteilung der Register auf jeweils zwei Register mit 32-Bit Lanes
- → Verhinderung von Overflows
- Vor der Berechnung der Wurzel: Konvertierung aller Lanes zu Floats mit ucvtf, um die Wurzel-Instruction fsqrt auf allen Lanes zu ermöglichen
- Anschließend: Cast zu Integer mit der Instruction fcvtzu



- 16-Bit Werte müssen zu 8-Bit Werten umgewandelt werden → Beschränkung der Lanes auf einen Maximalwert von 255
- Beispiel: Registers R = [0100 1001], welches 2 Lanes mit jeweils 4 Bit besitzt und auf vier beschränkt werden soll
- Das Register Q wird auf allen Lanes mit dem Maximalwert beschrieben:
  - $\rightarrow$  Q = [0010 0010]
- Erstellen einer Mask M über die Instruction cmhi mit dem Ergebnis-Register R und Q als Parameter
- M ist auf allen Lanes bitweise auf 1 gesetzt, wo R größer als der Wert von Q ist
  - → M = [0000 1111]



- Durch den bitweisen Operator & auf R und !M werden alle Lanes auf 0 gesetzt, die größer als der Maximalwert (im Beispiel: 4) sind
  - → R = R & !M = [0100 1001] & [1111 0000] = [0100 0000]
- In die auf 0 gesetzten Register muss nun der Maximalwert geschrieben werden
  - → Q = Q & M = [0010 0010] & [0000 1111] = [0000 0010]
- Anwendung des bitweisen Operator | auf R und Q
  - $\rightarrow$  R = R | Q = [0100 0000] | [0000 0010] = [0100 0010]



- Weil alle Pixel in einem 3x3-Bereich um den zu berechnenden Pixel benötigt werden, sind Randpixel nicht definiert
- Verwendung eines Paddings, in welchem die Randpixel nach außen gespiegelt werden
- Algorithmus wird auf ein in jede Richtung um ein Pixel erweitertes Bild ausgeführt

0	0	0
0	$E_{(0,0)}$	$E_{(1,0)}$
0	$E_{(0,1)}$	$E_{(1,1)}$

$E_{(0,0)}$	$E_{(0,0)}$	$E_{(1,0)}$
$E_{(0,0)}$	$E_{(0,0)}$	$E_{(1,0)}$
$E_{(0,1)}$	$\vec{E}_{(0,1)}$	$E_{(1,1)}$



# Genauigkeit

- Unterschiedlicher Genauigkeiten abhängig von Randbehandlung
- Resultate:









### Genauigkeit

$$A_{(x,y)}^{v,F} = \sum_{i=-k}^{k} \sum_{j=-k}^{k} M_{(k+i,k+j)}^{v} \cdot E_{(x+i,y+j)} \qquad G_{(x,y)}^{F} = \sqrt{(A_{(x,y)}^{v,F})^{2} + (A_{(x,y)}^{h,F})^{2}}$$

- Vertikale/Horizontale Komponente A des Ausgabe-Bildes kann größer als 255 sein
- A<sup>2</sup> kann in den 16-Bit Lanes der Summe in SIMD Overflow verursachen
- Laufzeit einsparen durch Akzeptieren das A selten Overflows verursacht
- Kernalgorithmus größenordnungsmäßig in O(n²)
- Mit Mirrored-Padding m + (n 2) zusätzliche Durchläufe



### Performanzanalyse

- Vergleich der Assembler-Implementierung zur C-Implementierung
- 8 verschiedene Modi durch 3 Parameter:
  - **Kompilierstufe:** Kompiliert mit Optimierungsstufe *O2* oder *O3*
  - Randstrategie: Skipped Edges oder Mirrored Padding Strategie
  - Implementierung: Standard-Implementierung in C, C-Implementierung mit

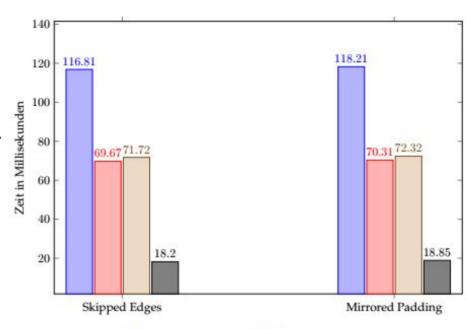
verbessertem Algorithmus, Standard-Assembler-Implementierung

oder Assembler mit SIMD-Operationen



### Performanzanalyse

- Kompiliert mit O3
- Kaum Unterschied zwischen den Randstrategien
- Extreme Differenz zwischen unoptimierter C-Implementierung und Assembler mit SIMD
- Wenig Differenz zwischen optimierter
   C-Implementierung und normaler
   Assembler-Implementierung
- Optimierte C-Implementierung schneller als Assembler-Implementierung ohne SIMD



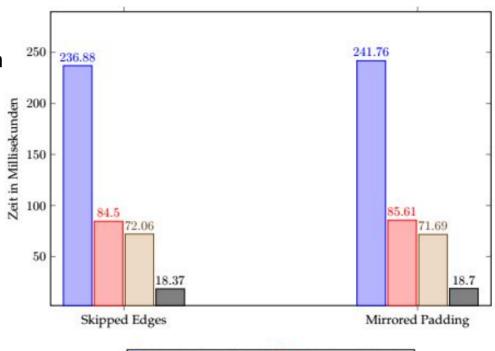
Unoptimierte C Impl. Optimierte C Impl.

Assembler ohne SIMD Assembler mit SIMD



### Performanzanalyse

- Kompiliert mit O2
- Erneut kaum Unterschied zwischen den Randstrategien
- Noch größere Differenz zwischen unoptimierter C-Implementierung und Assembler mit SIMD
- Größere Differenz zwischen normaler Assembler- und optimierter C-Implementierung
- Assembler immer schneller als C







### Zusammenfassung und Ausblick

- Mögliche Laufzeit-Verbesserung durch Berechnen der Quadrate in 16 Bit Lanes anstatt
   32 Bit Lanes, wobei mit Qualitätsverlust des Ergebnisses zu rechnen ist
- Marginale Verbesserungsmöglichkeit durch Integration der vertikalen Spiegelung der Mirrored Padding - Strategie in den Kernalgorithmus, zur Vermeidung redundanter Ladebefehle
- Extreme Performanzgewinne durch Nutzung vektorisierter Berechnungen in Assembler mit Hilfe von SIMD-Operationen
  - → Möglicherweise häufig lohnenswert, gewisse Berechnungen daher in Assembler / Inline-Assembler durchzuführen